

指导教师 签名栏	
	签名即确认纸质版与电子版终稿一致。

中国药科大学

本科毕业论文

中文题目 复杂疾病个体特异性因果网络构建及临界点预测

英文题目 Individual-Specific Casual Network Construction and
Tipping Point Prediction in Complex Disease

学 院 理学院

专 业 应用统计学（生物统计方向）

学 号 2020210606

姓 名 卜洋洋

指导教师 房婧雅

课 题
完成场所 理学院

论文工作时间： 2024 年 11 月 至 2025 年 05 月

承 诺 书

本人所呈交的纸质版毕业论文（设计）是个人在导师的指导下进行研究工作所取得的原创性研究成果，且与上传至学校毕业设计（论文）智能管理系统中的电子版终稿完全一致。

除参考文献中所列出的内容外，本论文（设计）不包含其他个人或集体已经发表或撰写过的研究成果。对本文的研究做出重要贡献的个人和集体，也已在文中明确说明并表示谢意。

在此，本人郑重承诺：如经核查，发现本人存在剽窃他人研究成果等学术不端行为，本人愿承担责任，并接受学校或相关部门关于学历、学位等方面的处理，且不受时间的限制。

作者签名：

日期：

目 录

目 录	1
摘 要	1
Abstract	2
第一章 前言	3
1.1 选题背景与研究目的	3
1.1.1 选题背景	3
1.1.2 研究目的	3
1.2 研究框架与理论依据	4
1.2.1 研究框架	4
1.2.2 理论依据	5
1.3 文献综述与研究现状	7
1.4 创新点	9
第二章 研究内容	10
2.1 基因调控网络的微分方程模拟	10
2.1.1 基因调控网络的生物学设定	10
2.1.2 基因调控网络的常微分方程	12
2.1.3 基因调控网络的数学分析	12
2.2 因果网络熵方法在 H3N2 流感上的应用	15
2.2.1 H3N2 流感数据 GSE30550 的基本情况	15
2.2.2 H3N2 流感数据 GSE30550 的分析设计	15
2.2.3 H3N2 流感数据 GSE30550 的分析目的	16
2.3 因果网络熵在 TCGA-READ 以及 TCGA-COAD 上的应用	16

2.3.1	TCGA-READ 数据的基本情况	16
2.3.2	TCGA-COAD 数据的基本情况	18
2.3.3	TCGA-READ 与 TCGA-COAD 的分析设计	19
2.3.4	TCGA-READ 与 TCGA-COAD 的分析目的	19
第三章 结果与讨论		20
3.1	基因调控网络数值模拟的因果网络熵分析结果	20
3.1.1	基因调控网络的统计指标	20
3.1.2	基因调控网络的因果强度指标	20
3.1.3	基因调控网络的熵指标	21
3.2	H3N2 流感的因果网络熵分析结果	22
3.2.1	识别个体 H3N2 流感恶化前状态的临界点	22
3.2.2	与临界点相关 DNB 模块的 GO 与 KEGG 通路分析	23
3.3	TCGA-READ 与 TCGA-COAD 的因果网络熵分析结果	24
3.3.1	识别 TCGA-READ 及 TCGA-COAD 的恶化前状态的分期阶段	24
3.3.2	临界点前后的生存差异	25
3.3.3	与临界点相关 DNB 模块的 GO 与 KEGG 通路分析	26
第四章 论文总结		28
4.1	总结	28
4.2	展望	28
参考文献		29
致 谢		31

摘 要

复杂疾病（如流感、癌症等）的发生和发展往往伴随着多维的生物学动态变化，演进方式具有非线性的特征，即存在从相对健康状态向严重发病状态的关键转变点。识别这种关键点对于公共卫生早期预防，疾病早期干预和治疗以及精准医疗至关重要。本研究定义了一种名为由简单统计指标驱动的个体特异性因果网络熵（Individual-Specific Causality Network Entropy Driven by Statistical Index, SI-ICNE）的新的计算模型，通过推断个体特异性因果网络，有效量化了特定生物分子群的动态变化关系。通过数值模拟评估了该方法的稳定性与有效性，在来自 GEO 数据库的 H3N2 流感数据集以及来自 TCGA 数据库的结肠腺癌以及直肠腺癌数据上证明了该方法在真实世界数据上的应用潜力。研究结果显示，该方法提前于 H3N2 流感临床症状的出现检测到了转变信号，准确预测了结直肠癌和的关键转变阶段，结果符合临床标准。此外，还对相关生物标志物进行了通路分析。

本研究主要分为四个部分。第一部分总结先前研究并提出理论；第二部阐明研究分析与目的；第三部分对研究结果进行解读；第四部分对本研究进行总结与展望。

关键词：复杂疾病；关键转变点；个体特异性；因果网络；熵；动态生物标志物

Abstract

The onset and progression of complex diseases(e.g., influenza, cancer, etc.) are often accompanied by multidimensional biological dynamics, and the evolutionary approach is characterized by a nonlinear nature, i.e., there are critical transition points from a state of relative health to a state of severe morbidity. Identifying such critical transition points is essential for public health early prevention, early clinical intervention and treatment, and precision medicine. In this study, we define a new computational model called Individual-Specific Causality Network Entropy Driven by Statistical Index (SI-ICNE), which effectively quantifies the dynamic relationship between specific groups of biomolecules. The stability and validity of the method is evaluated through numerical simulations, and the potential of the method to be applied on real-world data is demonstrated on the H3N2 influenza dataset from the GEO database as well as on colon adenocarcinoma and rectal adenocarcinoma data from the TCGA database. The results of the study showed that the method detects the critical transition signals in advance of H3N2 influenza and accurately predicts the critical transition stages of colorectal cancer and the results meet the clinical criteria. In addition, pathway analysis of relevant biomarkers is performed.

The study is divided into four main parts. The first part summarizes previous research and presents the theory; the second part clarifies the design and purpose of the research analysis; the third part interprets the results of the study; the last part concludes and looks forward to this study.

Keywords: complex diseases; critical transition points; individual specificity; causal networks; entropy; dynamic biomarkers

第一章 前言

1.1 选题背景与研究目的

1.1.1 选题背景

复杂疾病（如流感、癌症以及细胞退化）通常是由环境因素或者遗传因素引起生理稳态改变而造成的。大量研究结果表明，其发生和发展往往伴随着多尺度的生物学动态变化，呈现出时间、空间和功能上的高度异质性和非线性演进特征，即存在从健康状态或亚健康状态向恶化状态过渡的阶段，临床上将该阶段称为前驱期^[1]。如图 1.1-1 所示，在不考虑各种复杂疾病在临床症状上和生物学机制上的特殊差异的情况下，疾病的演进可以分为三个不同的阶段：生理稳定的相对健康状态，以恢复力减弱和易感性增加为特征的前驱期阶段，稳态破坏而造成的不可逆恶化阶段。随着时间进展，动态网络生物标志物（Dynamic Network Biomarkers, DNBs）引起显著的生理波动，当越过前驱期后，疾病将进入不可逆转的恶化状态。探查这种关键点以及对应的动态网络生物标志物对于疾病的早期快速诊断、精准干预和个性化治疗至关重要，不仅提供了理论基础，也开发了技术工具。




图 1.1-1 复杂疾病演进动态变化示意图

1.1.2 研究目的

目前对于复杂疾病的研究仍有以下几个缺点：1) 研究大多停留在群体水平，忽视了

个体内以及个体间的生物学差异；2）研究主要局限在静态基因表达分析，不考虑时间维度上的动态变化；3）仅从单个或者局部的生物标志物来分析疾病表现，未考虑生物标志物之间的网络影响关系。本研究通过构建复杂疾病的个体特异性因果网络，并预测疾病恶化的临界点，以揭示复杂疾病发生与发展的关键动态机制，尝试解决目前的研究缺陷以及拓展新的分析方法。

1.2 研究框架与理论依据

1.2.1 研究框架

本研究围绕个体特异性因果网络及临界点预测展开，结合单细胞转录组学（scRNA-Seq）数据，蛋白质相互作用网络（PPI），随机森林模型，因果熵方法和动态网络分析，探索个体化疾病进展的动态过程，并识别疾病恶化的临界点。根据 DNB 的统计学理论，本研究构建了由简单统计指标驱动的个体特异性因果网络熵（Individual-Specific Causality Network Entropy Driven by Statistical Index, SI-ICNE）模型，采用模拟数据与真实世界数据进行研究。利用常微分方程生成基因调控网络，主要评估统计熵方法的有效性与稳定性；在来自高通量基因表达数据库（Gene Expression Omnibus, GEO）^[2]的 GSE30550 流感数据^[3]中验证方法在真实世界数据上的潜力；在来自癌症基因图谱数据库（The Cancer Genome Atlas, TCGA）^[4]的 TCGA-COAD 结肠腺癌（Colon Adenocarcinoma, COAD）数据以及 TCGA-READ 直肠腺癌（Rectum Adenocarcinoma, READ）数据^[5]上证明方法的临床价值。

论文主要分为五个部分。

第一部分：前言。主要介绍了本研究的选题背景与研究目的，阐述了本研究的方法原理与研究步骤，论述了研究基础与研究现状，并指出本研究的创新之处。

第二部分：研究内容。从定量以及定性地设计了各部分的分析方案。在基因调控网络微分方程模拟部分，主要设计了符合生物学设定的具体微分方程，同时对微分方程进行数学分析；在 H3N2 流感分析部分，主要设计了针对 GSE30550 数据集的可行分析方案并阐明该数据集的主要分析目的；在 TCGA-COAD 以及 TCGA-READ 分析部分，主要设计了有关表达矩阵以及临床信息的分析方法，给出了两个数据集的基线信息并阐明了主要分析目的。

第四部分：结果与讨论。通过微分方程数值模拟统计指标、因果强度指标以及熵指标证明本研究提出方法的有效性；通过在 GSE30550 数据集上的应用，检验是否可以在 H3N2 流感临床症状出现前给出信号，同时对与 H3N2 流感有关的 DNBs 模块进行通路富集分析；通过在 TCGA-COAD 以及 TCGA-READ 等更复杂疾病数据上的应用，对相关疾病的恶化前临界阶段进行预测并分析有关 DNBs 模块的作用与功能。

第五部分：总结与展望。根据数值模拟结果与真实世界数据应用，总结本研究方法的优缺点，并进一步提出未来可以继续改进的部分。

如图 1.2-1 所示，为本研究框架：




图 1.2-1 研究框架

1.2.2 理论依据

DNB 相关理论^[6]认为，在疾病到达恶化前状态临界点时应当具有以下三个条件：（1）存在一群基因或者蛋白质，之间的平均 Pearson 相关系数（PCC）的绝对值急剧上升；（2）群组内基因或蛋白质的 PCCs 的绝对值显著上升，而与群组外的基因或者蛋白质之间的 PCCs 的绝对值显著下降；（3）群组内基因的平均标准差显著上升，发生较大波动。

根据 DNB 相关理论，本研究提出改进，具体理论依据与步骤如下：

【步骤 1】获取所研究复杂疾病的基因表达文件，确保各基因表达量已经过标准化处理并去除低表达量基因以及无效基因。

【步骤 2】将预处理后的基因与蛋白质相互作用网络数据库（Search Tool for Recurring Instances of Neighbouring Genes, STRING）^[7]中的 PPI 匹配，去除仅有单个节点而无任何邻接节点的基因。

【步骤 3】由于 PPI 网络映射得到的各个子网络内部是无方向性的，需要通过构建因果强度指数 w 来判断。对一个局部网络，有中心基因 g^k 以及邻接基因群 $\{g_j^k\}_{j=1}^M$ 。在时间 t 时，一个样本的基因间因果强度指数定义为 $w_t(g_j^k \rightarrow g^k) = SD(g_j^k) \cdot PCC(g_j^k \leftrightarrow g^k)$ ，其中， $SD(g_j^k)$ 为基因 g_j^k 表达量的标准差， $PCC(g_j^k \leftrightarrow g^k)$ 为基因 g_j^k 与基因 g^k 之间的 Pearson 相关系数。同时，可以认为 $w_t(g_j^k \rightarrow g^k) > 1$ 时，存在基因 g_j^k 到基因 g^k 的指向关系， $w_t(g_j^k \rightarrow g^k) \leq 1$ 时，不存在基因 g_j^k 到基因 g^k 的指向关系。同时，由 PPI 网络得到基因间互信息度 $I(g_j^k; g^k)$ 且 $I(g_j^k; g^k) > \beta \cdot \max_j I(g_j^k; g^k)$ ，其中 β 值根据研究需要选取。

【步骤 4】从时间 t 时该样本的全局因果网络 N_S 中提取 K 个局部因果网络 $\{LN_S^k\}_{k=1}^K$ ，将局部因果网络分为指入中心基因 g^k 的局部入度因果网络 $\{N_S^k\}_{k=1}^K$ 与中心基因指出的局部出度因果网络 $\{L_S^k\}_{k=1}^K$ 。其中， $N_S^k = \{g_{in,1}^k, g_{in,2}^k, \dots, g_{in,N}^k\}$ ， $L_S^k = \{g_{out,1}^k, g_{out,2}^k, \dots, g_{out,L}^k\}$ ，对应的有与中心基因的因果强度指数 $\{w(g_{in,1}^k \rightarrow g^k), w(g_{in,2}^k \rightarrow g^k), \dots, w(g_{in,N}^k \rightarrow g^k)\}$ 和 $\{w(g^k \rightarrow g_{out,1}^k), w(g^k \rightarrow g_{out,2}^k), \dots, w(g^k \rightarrow g_{out,L}^k)\}$ 。

【步骤 5】计算时间 t 时各局部因果网络的熵值 H^k ：

$$H^k = \alpha H_{in}^k + (1 - \alpha) H_{out}^k, \alpha = \frac{\sum_{j=1}^N w(g_{in,j}^k \rightarrow g^k)}{\sum_{j=1}^N w(g_{in,j}^k \rightarrow g^k) + \sum_{j=1}^L w(g^k \rightarrow g_{out,j}^k)} \quad (1.1)$$

其中， H_{in}^k 为局部入度因果网络的熵值， H_{out}^k 为局部出度因果网络的熵值，有：

$$\begin{cases} H_{in}^k = -\frac{\sum_{j=1}^N p_{in,j} \log(p_{in,j}) \sigma(FT(g^k)) e^{w_{in,j}}}{N}, \\ H_{out}^k = -\frac{\sum_{j=1}^L p_{out,j} \log(p_{out,j}) \sigma(\overline{FT}(g^k)) e^{w_{out,j}}}{L} \end{cases} \quad (1.2)$$

其中， $p_{in,j}$ 和 $p_{out,j}$ 为入度加权概率和出度加权概率， $FT(g^k)$ 和 $\overline{FT}(g^k)$ 分别为入度中心基因波动度和出度中心基因波动度， $\sigma(\cdot)$ 为 Sigmoid 函数，具体计算方式如下：

$$\begin{cases} p_{in,j} = \frac{w(g_{in,j}^k \rightarrow g^k) \cdot I(g_j^k; g^k)}{\sum_{j=1}^N w(g_{in,j}^k \rightarrow g^k) \cdot I(g_j^k; g^k)}, \\ p_{out,j} = \frac{w_{out}(g^k \rightarrow g_j^k) * I(g^k; g_j^k)}{\sum_{j=1}^N w_{out}(g^k \rightarrow g_j^k) * I(g^k; g_j^k)} \end{cases} \quad (1.3)$$

$$\begin{cases} FT(g^k) = \left| \frac{E_{case}(g^k) - \mu_{ref}(g^k)}{\sigma_{ref}(g^k)} \right|, \\ \overline{FT}(g^k) = \frac{\sum_{j=1}^L \left| \frac{E_{case}(g_j^k) - \mu_{ref}(g_j^k)}{\sigma_{ref}(g_j^k)} \right|}{L} \end{cases} \quad (1.4)$$

$$\begin{cases} \sigma(FT(g^k)) = \frac{1}{1 + e^{-FT(g^k)}}, \\ \sigma(\overline{FT}(g^k)) = \frac{1}{1 + e^{-\overline{FT}(g^k)}} \end{cases} \quad (1.5)$$

其中， $\mu_{ref}(\cdot)$ 和 $\sigma_{ref}(\cdot)$ 为参考样本基因表达量的平均值与标准差。

【步骤 6】将各局部因果网络的熵值从大到小排列，选取前 5%的网络计算 t 时刻全局因果网络熵，具体计算公式为：

$$H_t = \sum_{k=1}^{top5\% \cdot K} H^k \quad (2)$$

【步骤 7】根据各个时刻的全局因果网络熵值，确定临界点，同时确定 DNBs 模块。

1.3 文献综述与研究现状

近年来，随着转录组学、单细胞组学、空间组学等组学技术的发展，大量计算方法被用于监测复杂疾病的动态临界点。Chen 等（2012）^[6]提出了 DNB 方法，该方法基于拓扑网络变化，能够在疾病突变点到来之前提供早期预警信号。研究表明，即便在样本量较少的情况下，DNB 方法仍然能够检测到关键状态的转变。该方法已经在多个疾病模型中得到验证，并成为复杂疾病关键状态检测，细胞命运动态捕捉以及免疫检查点研究的重要理论依据和工具。传统的 DNB 方法存在需要多样本的局限性，随着研究进展，学者们提出了更多基于单样本的新方法。Liu 等（2014）^[8]进一步扩展了 DNB 方法，提出了一种基于单样本的关键状态检测方法。这一方法能够从能够在个体水平上识别复杂疾病恶化前状态，即在临床症状尚未显现时预测疾病进展，为精准医疗提供了新的视角。除了 DNB 方法之外，Chen 等（2016）^[9]采用隐马尔可夫模型（Hidden Markov Model, HMM），通过

状态转移概率识别复杂生物系统的相变临界点。Chen 等（2017）^[10]利用时间差分网络（Temporal Differentiation Networks）分析生物系统在突变点前后的网络变化结构。他们发现，随着疾病进展，分子网络的拓扑结构会发生显著的动态重构，而这一特性可以作为预测疾病恶化的重要信号。进一步地，Liu 等（2019）^[11]提出了一种景观动态网络生物标志物（landscape Dynamic Network Biomarker, *l*-DNB）方法，该方法结合分子网络的稳态景观分析，能够在单样本水平上检测复杂疾病的关键状态。研究结果显示，*l*-DNB 方法不仅能够预测疾病突变点，还能够识别影响疾病进展的核心基因模块。

目前，该领域的研究逐渐转向统计熵方法的开发。Han 等（2020）^[12]提出了一种基于单样本节点熵（Single-Sample Node Entropy, SSNE）的动态网络模型，用于检测癌症在恶化前的关键状态。该方法利用蛋白质相互作用网络，结合节点的熵值计算，识别癌症进展中的关键基因，并预测癌症恶化的临界点。Zhong 等（2022）^[13]提出了一种有向网络排序评分（Directed-network Rank Score）方法，这一方法结合网络动力学与统计排序，能够更加精准地捕捉生物系统的突变点，在细胞命运分析中展现了较高的准确性。与此同时，Zhong 等（2024）^[14]还引入了样本特异性网络熵（Sample-Specific Causality Network Entropy, SCNE）方法，通过推断个体水平的因果关系网络，捕捉关键状态的变化情况。SCNE 方法在单细胞数据分析中表现优异，尤其适用于高维、小样本数据集。Yan 等（2025）^[15]使用了一种基于单样本网络信息增益（Network Information Gain, NIG）的疾病预测方法，通过分析基因网络模块和网络流熵（Network Flow Entropy），能够高效检测复杂疾病的关键过渡状态并识别 DNB 及潜在靶点。通过揭示“暗基因”和特定调控基因（Specific-RGs）的功能角色，为个体化疾病诊断和精准医学提供了新思路。

上述这些计算方法在特定疾病当中得到成功应用。Chen 等（2015）^[16]将 DNB 方法应用于乳腺癌 MCF-7 细胞分化的研究中，成功识别了乳腺癌细胞的早期分化状态。Liu 等（2019）^[17]研究了乳腺癌的内分泌耐药性，并利用 DNB 方法检测耐药发生的关键状态。他们发现，某些基因突变在乳腺癌细胞获得耐药性之前就已发生，而 DNB 方法能够准确预测这一转变过程，为个性化药物调整提供了数据支持。Sun 等（2020）^[18]将 *l*-DNB 方法应用于肝癌进展的临界状态检测。研究发现，低级别和高级别肝硬化是肝癌发展的关键节点。这一发现有助于优化肝癌的早期干预策略，提高患者的生存率。

1.4 创新点

本研究的主要创新点如下：

1. 从个体水平定量动态分析复杂疾病的进展过程并预测恶化前关键状态的时刻；
2. 简化了因果网络的构建方式，尤其是在判断是否存在显著因果关系部分；
3. 平衡了基因间因果强度与基因波动度的影响，使系统不会因为某一方出现极端情况而降低精度；
4. 准确识别了 DNB 模块关键基因，从而可以分析相关生物学通路。

第二章 研究内容

2.1 基因调控网络的微分方程模拟

2.1.1 基因调控网络的生物学设定

基因调控网络的构建首先要符合生物学过程，即正负反馈调节机制。现实情况下的基因调控网络十分复杂，故在此进行简化，利用酶促动力学中的米氏方程（Michaelis-Menten Equation）^[19]进行模拟。

在本研究中，米氏方程主要用来描述基因之间存在的正向关系与负向关系。

对于正向关系，有：



其中， E 为酶， S 是反应底物， P 为产物， ES 为反应中间体， K_1 ， K_{-1} ， K_2 为平衡常数。当反应处于稳定状态时， ES 的生成速率与分解速率相等，即有：

$$K_1[E][S] = K_{-1}[ES] + K_2[ES] \quad (3.2)$$

其中， $[\cdot]$ 表示浓度，反应系统中酶的总浓度为 $[E_t] = [E] + [ES]$ ，对公式(3.2)进行变换得：

$$K_1([E_t] - [E])[S] = K_{-1}[ES] + K_2[ES] \quad (3.3)$$

$$\Rightarrow [ES] = \frac{K_1[E_t][S]}{K_1[S] + K_{-1} + K_2} \quad (3.4)$$

$$\Rightarrow [ES] = \frac{[E_t][S]}{\frac{K_{-1} + K_2}{K_1} + [S]} \quad (3.5)$$

令 $K_m = \frac{K_{-1} + K_2}{K_1}$ ，于是公式(3.5)变为 $[ES] = \frac{[E_t][S]}{K_m + [S]}$ ， K_m 为米氏常数。由于产物 P 的生成速率取决于第二步即 K_2 ，从近似的角度来说 $v \approx K_2[ES]$ ，则

$$v \approx \frac{K_2[E_t][S]}{K_m + [S]} \quad (3.6)$$

当所有酶分子全部结合底物，即 $[E_t] = [ES]$ ，有

$$v \approx \frac{v_{max}[S]}{K_m + [S]} \quad (3.7)$$

公式(3.7)简化后提取促进项 $\frac{[S]}{K_m + [S]}$ 。

对于负向关系，有：



其中， I 为抑制剂， S 是反应底物， IS 为失活体， K 为平衡常数。底物总浓度 $[S_t] = [S] + [IS]$ ，

IS 的生成速率 $[IS] = \frac{[I][S]}{K}$ ，则

$$[S_t] = [S] + \frac{[I][S]}{K} \quad (3.9)$$

$$\Rightarrow [S] = \frac{K}{K + [I]} [S_t] \quad (3.10)$$

公式(3.10)简化后提取抑制项 $\frac{K}{K+[I]}$ 。

如图 2.1-1 所示，本研究模拟了包含 5 个节点的基因调控网络^[20]，其中节点 1 和节点 2 为 DNB 模块。以节点 1，节点 2 和节点 3 为例，节点 1 对节点 2 有抑制作用，节点 3 对节点 1 有抑制作用，同时节点 3 对节点 2 有促进作用，假设节点 1 的自身衰减率为 α ，节点 2 的自身衰减率为 β ，节点 3 的自身衰减率为 γ ，用如下微分方程组可以描述这三个节点的行为：

$$\begin{cases} \frac{dg_1}{dt} = -\alpha G_1 + k_1 \frac{K_3}{K_3 + G_3} + \varsigma_1(t), \\ \frac{dg_2}{dt} = -\beta G_2 + k_2 \frac{K_1}{K_1 + G_1} + k_3 \frac{K_3}{K_3 + G_3} + G_3 + \varsigma_2(t) \end{cases} \quad (3.11)$$

其中， $k_i(i = 1,2,3)$ 为常数系数， $\varsigma_i(t)(i = 1,2) \sim N(0, \sigma^2)$ 为高斯噪声项。总的来说，单个节点的调控方程形式为：

$$\frac{dg_i}{dt} = \text{促进项} + \text{抑制项} - \text{衰减项} + \text{噪声项} \quad (3.12)$$




图 2.1-1 5 节点基因调控网络

2.1.2 基因调控网络的常微分方程

假设系统中所有平衡常数为 1，以下为图 2.1-1 的具体常微分方程组：

$$\begin{cases} \frac{dg_1}{dt} = (30|s| - 180) + (120 - 40|s|) \frac{1}{1 + g_3} + 240 \frac{g_4}{1 + g_4} - 10|s|g_1 + \varsigma_1(t), \\ \frac{dg_2}{dt} = (40|s| - 90) + (120 - 40|s|) \frac{1}{1 + g_1} + (120 - 40|s|) \frac{g_3}{1 + g_3} - 30g_2 + \varsigma_2(t), \\ \frac{dg_3}{dt} = -90 + 240 \frac{g_4}{1 + g_4} - 30g_3 + \varsigma_3(t), \\ \frac{dg_4}{dt} = -180 + 400 \frac{g_5}{1 + g_5} - 60g_4 + \varsigma_4(t), \\ \frac{dg_5}{dt} = 40 \frac{1}{1 + g_1} + 40 \frac{1}{1 + g_2} + 240 \frac{1}{1 + g_4} - 200g_5 + \varsigma_5(t) \end{cases} \quad (4.1)$$

其中， s 为常数参数。在时间 $[t, t + 1)$ 中，将常微分方程组(4.1)以欧拉方程组形式^[21]表示：

$$\begin{cases} g_1(k + 1) = g_1(k) + \frac{dg_1}{dt} \cdot \Delta t, \\ g_2(k + 1) = g_2(k) + \frac{dg_2}{dt} \cdot \Delta t, \\ g_3(k + 1) = g_3(k) + \frac{dg_3}{dt} \cdot \Delta t, \\ g_4(k + 1) = g_4(k) + \frac{dg_4}{dt} \cdot \Delta t, \\ g_5(k + 1) = g_5(k) + \frac{dg_5}{dt} \cdot \Delta t \end{cases} \quad (4.2)$$

其中， k 代表时间 $[t, t + 1)$ 中的一个极限时间点。

2.1.3 基因调控网络的数学分析

以欧拉方法对调控方程进行时间离散化得到抽象形式：

$$g_i(k + 1) = g_i(k) + f[g(k); s] \cdot \Delta t \quad (5.1)$$

其中， $g(k)$ 为 k 时刻的状态变量， $f[g(k); s]$ 为非线性项，该方程所描述的是一段时间 $[t, t + 1)$ 内的累积，即

$$\begin{cases} dg_i = g_i(k + 1) - g_i(k), \\ g_i(k) = g_i(t + k \Delta t) \end{cases} \quad (5.2)$$

当达到平衡状态 $\bar{g}$ 时，有 $f(\bar{g}; s) = 0$ 且 $\frac{dg_i}{dt} = 0$ 。

令 $x_i(k+1) = g_i(t) - \bar{g}$ ，即将平衡点移到原点，方程变为：

$$x_i(k+1) = x_i(k) + f[x(k) + \bar{g}; s] \cdot \Delta t \quad (5.3)$$

对非线性项 $f[x(k) + \bar{g}; s]$ 进行泰勒展开^[22]，保留一阶形式：

$$f[x(k) + \bar{g}; s] \approx f(\bar{g}; s) + \left. \frac{\partial f}{\partial g} \right|_{g=\bar{g}} x(k) \quad (5.4)$$

于是，方程变为：

$$x_i(k+1) = x_i(k) + \left. \frac{\partial f}{\partial g} \right|_{g=\bar{g}} x(k) \Delta t \quad (5.5)$$

有雅各比（Jacobian）矩阵 $J = \left. \frac{\partial f[g(k); s]}{\partial g} \right|_{g=\bar{g}} = e^{\Delta t \cdot A}$ ，则有精确解：

$$x(k+1) = J \cdot x(k) \quad (5.6)$$

存在可逆矩阵 P ，使得 $P^{-1}JP = \Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n)$ ，其中， λ_i 为矩阵 J 的特征值。

简化方程形式，将 $g(k)$ 转换为 $y(k)$ ，即 $g(k) \rightarrow x(k) \rightarrow y(k)$ 。 $x(k) = Py(k)$ ，则 $y(k) = P^{-1}x(k)$ ，使得

$$y(k+1) = \Lambda y(k) + \zeta(k) \quad (5.7)$$

据此，可以计算 y 的标准差，Pearson 相关系数：

$$SD(y_i) = \sqrt{\text{Var}[y_i(k+1)]} = \sqrt{E[y_i^2(k+1)]} = \sqrt{\lambda_i^2 \text{Var}(y_i) + \kappa_{ii}} \quad (5.8)$$

$$PCC(y_i, y_j) = \frac{\text{Cov}(y_i, y_j)}{\sqrt{\text{Var}(y_i)\text{Var}(y_j)}} = \frac{\kappa_{ij}}{\kappa_{ii}\kappa_{jj}} \frac{\sqrt{(1-\lambda_i^2)(1-\lambda_j^2)}}{1-\lambda_i\lambda_j} \quad (5.9)$$

其中， κ_{ij} 为高斯噪声协方差矩阵中的元素，即 $\kappa_{ij} = \text{Cov}(\zeta_i(t), \zeta_j(t))$ 。通过线性变换，即可得到 $g(k)$ 的标准差与相关系数。

在该部分模拟的基因调控网络中，设平衡状态浓度 $\bar{g} = \{g_1, g_2, g_4, g_4, g_5\} = \{1, 1, 1, 1, 1\}$ ，个节点衰减率 $DR = \{10|s|, 30, 30, 60, 200\}$ ，有雅各比矩阵 $J = e^{\Delta t \cdot A}$ ，其中矩阵 A 如下：

$$A = \begin{bmatrix} -10|s| & 0 & 10|s| - 30 & 60 & 0 \\ 10|s| - 30 & -30 & 30 - 10|s| & 0 & 0 \\ 0 & 0 & -30 & 60 & 0 \\ 0 & 0 & 0 & -60 & 100 \\ -20 & -20 & 0 & -60 & -200 \end{bmatrix} \quad (5.10)$$

取 $\Delta t = 0.01$ ，得到矩阵 J 的 5 个不同特征值 $(0.905^{|s|}, 0.741, 0.643, 0.333, 0.257)$ ，进一步可求得可逆矩阵 P ：

$$P = \begin{bmatrix} -1 & 1 & -3\sqrt{21}-13 & \frac{3}{2} & 3\sqrt{21}-13 \\ 1 & -1 & 0 & 0 & 0 \\ 0 & 1 & -3\sqrt{21}-13 & \frac{3}{2} & 3\sqrt{21}-13 \\ 0 & 0 & \frac{5\sqrt{21}+15}{6} & -2 & \frac{-5\sqrt{21}+15}{6} \\ 0 & 0 & 1 & 1 & 1 \end{bmatrix} \quad (5.11)$$

使得 $P^{-1}JP = \Lambda = \text{diag}(0.905^{|s|}, 0.741, 0.643, 0.333, 0.257)$ ，于是有 $y(k+1) = \Lambda y(k) + \varsigma(k)$ ，如下：

$$\begin{cases} y_1(k+1) = 0.905^{|s|}y_1(k) + \varsigma_1(k), \\ y_2(k+1) = 0.741y_2(k) + \varsigma_2(k), \\ y_3(k+1) = 0.643y_3(k) + \varsigma_3(k), \\ y_4(k+1) = 0.333y_4(k) + \varsigma_4(k), \\ y_5(k+1) = 0.257y_5(k) + \varsigma_5(k) \end{cases} \quad (5.12)$$

由此可知，变换后只有 y_1 受到参数 s 的影响。如所示，当 $s \rightarrow 0$ 时， $\lambda_1 = 0.905^{|s|} \rightarrow 1$ ， $SD(y_1) \rightarrow \infty$ 。由可逆矩阵 P 可知，第一列向量为 $(-1, 1, 0, 0, 0)$ ，只与节点 1 于节点 2 有关，与设定中节点 1 与节点 2 为 DNB 模块高度符合。




图 2.1-2 各 y 值标准差变化

2.2 因果网络熵方法在 H3N2 流感上的应用

2.2.1 H3N2 流感数据 GSE30550 的基本情况

GSE30550 数据集是 GEO 数据库中来自美国密歇根大学（University of Michigan）的一项关于人类宿主对 H3N2 流感病毒病原体的转录反应研究。其使用高通量测序技术对 17 个感染了 H3N2 受试对象进行了 Baseline + 15 个时间点上的全基因测序。如表 2.2-1 所示，该 17 个受试对象在是否出现感染后临床症状以及发生时间存在差异。

表 2.2-1 17 个 H3N2 流感感染受试对象基线信息

Sample information of GSE30550 datasets from GEO		
Subject	Presence of Clinical Symptoms	Time Point
Subject 01	Symptomatic	Hour 045(point 7)
Subject 02	Asymptomatic	
Subject 03	Asymptomatic	
Subject 04	Asymptomatic	
Subject 05	Symptomatic	Hour 045(point 7)
Subject 06	Symptomatic	Hour 045(point 7)
Subject 07	Symptomatic	Hour 045(point 7)
Subject 08	Symptomatic	Hour 069(point 10)
Subject 09	Asymptomatic	
Subject 10	Symptomatic	Hour 077(point 11)
Subject 11	Asymptomatic	
Subject 12	Symptomatic	Hour 093(point 13)
Subject 13	Symptomatic	Hour 101(point 14)
Subjct 14	Asymptomatic	
Subject 15	Symptomatic	Hour 101(point 14)
Subject 16	Asymptomatic	
Subject 17	Asymptomatic	

2.2.2 H3N2 流感数据 GSE30550 的分析设计

以下为 H3N2 流感数据 GSE30550 分析设计与步骤：

【步骤 1】获取 17 个受试对象各自的时间基因表达矩阵，即行为各个测序基因，列为 Baseline+15 个时间点，并去除低表达基因。

【步骤 2】使用 STRING 数据库，将测序基因匹配到 PPI 网络上，去除无信息节点以及单个无邻接的节点。

【步骤 3】对各个受试对象的每个时间点计算因果网络熵，以 Baseline+前 3 个时间点为参照样本。

【步骤 4】对比分析各个受试对象的因果网络熵时序变化情况，判断是否能够在临床症状发生前检测到疾病信号。

【步骤 5】确定在临界点处的 DNB 模块，对其中心基因进行基因本体 (Gene Ontology, GO)^[23]与京都基因与基因组百科全书 (Kyoto Encyclopedia of Genes and Genomes, KEGG)^[24]通路富集分析，以明确中心基因的主要功能。

2.2.3 H3N2 流感数据 GSE30550 的分析目的

通过基因调控网络数值模拟，已经证明了本研究提出的因果熵方法的可用性与稳定性，但还未明确在真实世界数据上的潜力。H3N2 流感数据 GSE30550 的分析目的主要是通过计算是否可以提前于临床症状发生时间，检测到疾病恶化信号，评估本研究的方法在真实世界数据集上的有效性，为下一步使用该方法进行复杂疾病预测夯实基础。同时，在该数据集上还进一步分析相关 DNB 模块中心基因的功能，为发现 H3N2 流感新的靶通路提供了新的视角。

2.3 因果网络熵在 TCGA-READ 以及 TCGA-COAD 上的应用

2.3.1 TCGA-READ 数据的基本情况

TCGA-READ 是由美国国家癌症研究所 (National Cancer Institute, NCI) 和美国国家人类基因组研究所 (National Human Genome Research Institute, NHGRI) 联合启动项目 TCGA 中关于直肠腺癌 (Rectal Adenocarcinoma) 患者的多组学数据。直肠腺癌是消化道常见的单一类型恶性肿瘤，占结直肠癌的 20%-30%^[25]。本研究中共采用 161 位患者的转录组学数据与临床数据，161 位患者的基线信息如表 2.2-1 所示，组间没有显著差异。

表 2.3-1 161 位直肠腺癌患者的基线信息

Baseline information for 161 active patients with rectal adenocarcinoma(READ)					
Stage	Stage I (N=33)	Stage II (N=51)	Stage III (N=52)	Stage IV (N=25)	Overall (N=161)
Age—yr					
Mean ± SD	64.70±12.28	65.96±10.23	62.79±12.36	63.56±13.11	64.30±11.79
Median[min-max]	66.00[35.00,86.00]	66.00[47.00,90.00]	66.00[31.00,89.00]	64.00[41.00,86.00]	66.00[31.00,90.00]
Gender—no.(%)					
Male	19(11.80%)	27(16.77%)	25(15.53%)	16(9.94%)	87(54.04%)
Female	14(8.70%)	24(14.91%)	27(16.77%)	9(5.59%)	74(45.96%)
Race—no.(%)					
White	10(6.21%)	21(13.04%)	31(19.25%)	12(7.45%)	74(45.96%)
Asian	0(0.00%)	1(0.62%)	0(0.00%)	0(0.00%)	1(0.62%)
American Indian or Alaska Native	0(0.00%)	0(0.00%)	0(0.00%)	0(0.00%)	0(0.00%)
Black or African American	1(0.62%)	2(1.24%)	2(1.24%)	1(0.62%)	6(3.73%)
Not Reported	22(13.66%)	27(16.77%)	19(11.80%)	12(7.45%)	80(49.69%)
Enthnicity—no.(%)					
Hispanic or Latino	0(0.00%)	0(0.00%)	0(0.00%)	0(0.00%)	0(0.00%)
Not Hispanic or Latino	11(6.83%)	24(14.91%)	31(19.25%)	13(8.07%)	79(49.07%)
Not Reported	22(13.66%)	27(16.77%)	21(13.04%)	12(7.45%)	82(50.93%)
Histological Type— no.(%)					
Rectal Adenocarcinoma	30(18.63%)	43(26.71%)	47(29.19%)	23(14.29%)	143(88.82%)
Rectal Mucinous Adenocarcinoma	1(0.62%)	6(3.73%)	4(2.48%)	1(0.62%)	12(7.45%)
Not Reported	2(1.24%)	2(1.24%)	1(0.62%)	1(0.62%)	6(3.73%)

2.3.2 TCGA-COAD 数据的基本情况

TCGA-COAD 是由美国国家癌症研究所和美国国家人类基因组研究所联合启动项目 TCGA 中关于结肠腺癌（Colon Adenocarcinoma）患者的多组学数据。结肠腺癌是消化道又一常见的单一类型恶性肿瘤，占结直肠癌的 50%-60%^[26]。本研究中共采用 448 位患者的转录组学数据与临床数据，448 位患者基线信息如所示，组间没有显著差异。

表 2.3-2 448 位结肠腺癌患者的基线信息

Baseline information for 448 active patients with colon adenocarcinoma(COAD)					
Stage	Stage I (N=76)	Stage II (N=178)	Stage III (N=129)	Stage IV (N=65)	Overall (N=448)
Age—yr					
Mean ± SD	68.09±12.00	69.09±12.78	64.96±13.74	63.74±12.92	66.94±13.09
Median[min-max]	70.50[36.00,89.00]	70.50[31.00,89.00]	66.00[34.00,90.00]	66.00[35.00,85.00]	69.00[31.00,90.00]
Gender—no.(%)					
Male	42(9.38%)	94(20.98%)	65(14.51%)	35(7.81%)	236(52.68%)
Female	34(7.59%)	84(18.75%)	64(14.29%)	30(6.70%)	212(47.32%)
Race—no.(%)					
White	34(7.59%)	78(17.41%)	64(14.29%)	28(6.25%)	204(45.54%)
Asian	0(0.00%)	10(2.23%)	1(0.22%)	0(0.00%)	11(2.46%)
American Indian or Alaska Native	0(0.00%)	0(0.00%)	1(0.22%)	0(0.00%)	1(0.22%)
Black or African American	8(1.79%)	19(4.24%)	21(4.69%)	11(2.46%)	59(13.17%)
Not Reported	34(7.59%)	71(15.85%)	42(9.38%)	26(5.80%)	173(38.62%)
Enthnicity—no.(%)					
Hispanic or Latino	0(0.00%)	1(0.22%)	1(0.22%)	2(0.45%)	4(0.89%)
Not Hispanic or Latino	40(8.93%)	104(23.21%)	84(18.75%)	36(8.04%)	264(58.93%)
Not Reported	36(8.04%)	73(16.29%)	44(9.82%)	27(6.03%)	180(40.18%)
Histological Type— no.(%)					

Colon	65(14.51%)	153(34.15%)	105(23.44%)	58(12.95%)	381(86.00%)
Adenocarcinoma					
Colon Mucinous	9(2.01%)	24(5.36%)	22(4.91%)	7(1.56%)	62(14.00%)
Adenocarcinoma					
Not Reported	2(0.45%)	1(0.22%)	2(0.45%)	0(0.00%)	5(1.12%)

2.3.3 TCGA-READ 与 TCGA-COAD 的分析设计

以下为 TCGA-READ 与 TCGA-COAD 的分析设计与步骤：

【步骤 1】获取 TCGA-READ 与 TCGA-COAD 的所有转录组基因表达矩阵与临床信息，转录组基因表达矩阵格式为行为测序基因，列为患者组织样本，并去除低表达基因。

【步骤 2】使用 STRING 数据库，将测序基因匹配到 PPI 网络上，去除无信息节点以及单个无邻接的节点。

【步骤 3】将患者组织样本与临床分期匹配，计算各临床分期对应患者组织样本基因表达量的平均值，标准差以及各基因间相关系数。

【步骤 4】对各分期计算因果网络熵，以正常组织样本为参考样本。

【步骤 5】对比分析各分期的因果网络熵时序变化情况，并预测癌症恶化临界分期。

【步骤 6】以临界分期为分隔点，分析前后患者的生存情况，评估该分期作为临界点的效果。

【步骤 7】确定在临界分期处的 DNB 模块，对其进行 GO 与 KEGG 通路富集分析，以明确 DNB 模块的主要功能。

2.3.4 TCGA-READ 与 TCGA-COAD 的分析目的

通过基因调控网络数值模拟以及 GSE30550 流感数据的应用，已经证明了本研究所提出的因果网络熵方法具有相当的潜力。该部分主要将其拓展到癌症疾病上，评估在未知情况下，其是否可以预测相关癌症即将发生恶化的临界点，从而能够为临床进一步的研究提供依据。通过生存分析，评估临界点的效果，同时分析相关 DNB 模块的功能，发现新的靶通路。

第三章 结果与讨论

3.1 基因调控网络数值模拟的因果网络熵分析结果

3.1.1 基因调控网络的统计指标

根据 DNB 理论，DNB 模块内的基因在临界点附近会出现标准差以及 Pearson 相关系数显著增大的情况。如图 3.1-1 所示，参数 s 为模拟的外界刺激，当 $s \rightarrow 0$ 时，即当系统逐渐趋向于临界状态时，节点 1 与节点 2 的表达量的标准差发生显著增长（A），而其他节点在参数 s 的不断变化下仍保持平稳。同时，节点 1 与节点 2 的 Pearson 相关系数（PCC）的绝对值在 $s \rightarrow 0$ 时显著上升，节点 1 与其他邻接节点，即节点 3，节点 4 以及节点 5，Pearson 相关系数的绝对值显著下降。结果证明了，DNB 模块在系统到达关键状态时，标准差以及内部 Pearson 相关系数显著增大，而与外部 Pearson 相关系数显著减小。




图 3.1-1 模拟基因调控网络统计指标

3.1.2 基因调控网络的因果强度指标

根据中心极限理论，基因的表达大部分符合正态分布^[27]。如图 3.1-2 所示，认为各节点表达量的分布为以 10 份参考样本各节点表达量的均值和方差为参数的正态分布。波动度是用来衡量各参数 s 下节点偏离正常值的程度（A），当 $s \rightarrow 0$ 时，即当系统逐渐趋向于临界状态时，节点 1 和节点 2 显著偏离 0，说明节点 1 和节点 2 出现异常表达，而其他节点在 0 附近平稳波动，说明未出现异常表达。同时，评估了各对相互作用的节点正反两个方向共 16 个因果强度指数（B），发现节点 1 和节点 2 的正反两个方向，即节点 1→节点 2 以及节点 2→节点 1 的因果强度指数增长最为显著，推测其余关系如节点 1→节点 3、节点 1→节点 4、节点 1→节点 5 的因果强度指数是由于节点 1 的显著变异而造成的伪增长，

故可以不用考虑。




图 3.1-2 模拟基因调控网络因果强度指标

3.1.3 基因调控网络的熵指标

由统计指标以及因果强度指标初步证明了模拟系统中的 DNB 模块在临界状态处会发生显著变化。由统计指标与因果强度指标共同计算而来的因果网络熵指标进一步证明了这一点。如图 3.1-3 所示，全局因果网络熵在 $s \rightarrow 0$ 的小范围区间内显著增大，在其他 s 值下保持 0 附近的平稳波动。统计指标，因果强度指标以及因果网络熵指标联合证明了本研究提出的因果网络熵计算方法在数值上的稳定性与有效性，可以进一步应用到真实世界数据中。




图 3.1-3 模拟基因调控网络因果网络熵指标

3.2 H3N2 流感的因果网络熵分析结果

3.2.1 识别个体 H3N2 流感恶化前状态的临界点

由表 2.2-1 中 17 位受试对象的基线信息得到共有 9 位受试对象在监测时间内出现了临床症状，其余 8 位受试对象在监测时间段内并没有出现临床症状。如所示，受试对象 1 在时间点 5 时出现了熵值信号，提前临床症状出现 2 个时间点；受试对象 5 在时间点 7 时出现了熵值信号，此处恰好为临床症状出现时间点；受试对象 6 在时间点 6 时出现了熵值信号，提前临床症状出现 1 个时间点；受试对象 7 在时间点 7 时出现了熵值信号，此处恰好为临床症状出现时间点；受试对象 8 在时间点 9 时出现了熵值信号，提前临床症状出现 1 个时间点；受试对象 10 在时间点 11 时出现了熵值信号，此处恰好为临床症状出现时间点；受试对象 12 在时间点 9 出现了熵值信号，提前临床症状 4 个时间点；受试对象 13 在时间点 9 时出现熵值信号，提前临床症状出现 5 个时间点；受试对象 15 在时间点 11 时出现熵值信号，提前临床症状出现 3 个时间点。在监测时间内出现了临床症状的 9 位受试对象中，均不同程度地提前检测到了流感发病的信号，说明本研究所提前的方法在真实世界数据上具有一定实用性。




图 3.2-1 有症状受试对象因果网络熵组图

如表 2.2-1 所示，其他 8 位受试对象在监测时间段内，熵值并未出现显著波动。特殊

情况如受试对象 3，在时间点 15 处出现了急剧上升的熵值信号，推测受试对象 3 即将出现临床症状，但并未在监测时间段内出现。




图 3.2-2 无症状受试对象因果网络熵组图

3.2.2 与临界点相关 DNB 模块的 GO 与 KEGG 通路分析

汇总 9 位有症状受试对象的 DNB 模块中心基因，进行 GO 和 KEGG 通路富集分析。

如图 3.2-3 所示，GO 通路富集分析结果显示（A 和 C），所得到的 DNB 模块中心基因主要与 10 个细胞结构，生物过程以及通路有关。大致可以分为三类：（1）由含蛋白复合体（Protein-containing Complex），核质（Nucleoplasm），胞质溶胶（Cytosol）组成的细胞结构和功能调控；（2）由共生体过程（Symbiont Process），种间相互作用作用（Interspecies Interaction），病毒过程（Viral Process），多生物过程（Multi-organism Process）组成的生物间相互作用与共生关系；（3）由对有机物的反应（Response to Organic Substance），细胞对有机物的反应（Cellular Response to Organic Substance），胁迫反应（Response to Stress）组成的应激适应机制^[28]。DNB 模块中心基因反映了宿主机体感染 H3N2 流感病毒后，与病毒相互抵抗的过程，在临界时点处，病毒加速演进，通过与宿主因子互作来促进病毒复制并拮抗宿主的干扰素反应，同时引起宿主机体产生炎症反应与免疫反应^[29]，如应对氧化应激，激活保护性通路。

KEGG 通路富集分析结果显示（B 和 D），DNB 模块中心基因机制主要与 10 个通路有关：（1）由乙型/丙型肝炎（Hepatitis B/C），人乳头瘤病毒感染（Human Papillomavirus Infection），卡波西肉瘤相关疱疹病毒/人巨细胞病毒感染（Kaposi Sarcoma-associated Herpesvirus/Human Cytomegalovirus Infection）组成的病毒感染与宿主互作机制；（2）由阿尔茨海默病（Alzheimer disease），亨廷顿病（Huntington disease）组成的神经退行性疾

病机制；(3)由癌症相关通路(Pathways in Cancer), PI3K-Akt 信号通路(PI3K-Akt Signaling Pathway), 细胞周期(Cell Cycle)组成的癌症发生机制。这些机制反映了 H3N2 流感病毒感染后存在和多种其他类型疾病的交叉反应。当 H3N2 流感病毒感染较为严重时, 会诱发其他类型的疾病。结果说明, 由本研究所提出的因果网络熵方法可以很好地捕捉 H3N2 流感相关 DNB 模块, 为进一步在癌症疾病上的应用提供了现实依据。




图 3.2-3 GSE30550 的 GO 与 KEGG 通路富集分析组图

3.3 TCGA-READ 与 TCGA-COAD 的因果网络熵分析结果

3.3.1 识别 TCGA-READ 及 TCGA-COAD 的恶化前状态的分期阶段

如图 3.3-1 所示,TCGA-COAD 中样本的因果网络熵在临床 III 期时发生显著增大(A),所以本研究中将临床 III 期附近作为结肠腺癌的关键转变点;TCGA-READ 中样本的因果网络熵在临床 IV 期时发生显著变化,所以将本研究中将临床 IV 期附近作为直肠腺癌的关键转变点。临床标准指出^[30],结肠腺癌在 III 期阶段已侵犯到结肠壁和周围组织,还发生了淋巴结转移;直肠腺癌整体进展情况较慢,临床 IV 期才会通过血液和淋巴结开始向全身扩散,形成肝转移和肺转移。同时,其他类似计算方法也得出了结肠腺癌的临界点位于临床 III 期^[31]。




图 3.3-1 TCGA-COAD 和 TCGA-READ 因果网络熵组图

3.3.2 临界点前后的生存差异

由 3.3.1 得到 TCGA-COAD 的临界点为临床 III 期，TCGA-READ 的临界点为临床 IV 期，故采用 KM 方法^[32]对临界点前后的患者进行生存分析。

KM 方法计算生存率的具体公式为：

$$\widehat{S}(t) = \prod_{i:t_i \leq t} \left(1 - \frac{d_i}{n_i}\right) \quad (6)$$

其中， d_i 为 t_i 时刻发生死亡事件的人数， n_i 为 t_i 时刻的剩余人数。计算各时刻临界点前后患者生存率，并采用对数秩检验（Log Rank test）对组间生存率是否存在差异进行检验。

如所示，TCGA-COAD 中临界点前后患者生存率存在显著差异（A, $p \leq 0.05$ ），临界点前患者生存率显著高于临界点后患者生存率；TCGA-READ 中临界点前后患者生存率差异并不显著（B, $p = 0.054$ ），但临界点前患者生存率在趋势上高于临界点后患者生存率，推测由于样本量不足导致无法捕捉到差异。临界点选择恰当。




图 3.3-2 TCGA-COAD 和 TCGA-READ 临界点前后患者生存差异组图

3.3.3 与临界点相关 DNB 模块的 GO 与 KEGG 通路分析

如图 3.3-3 所示，TCGA-COAD 的 DNB 模块的 GO 通路富集分析（A 和 C）主要围绕细胞外基质（Extracellular Matrix, ECM）动态调控以及免疫-微环境互作两大核心生物功能。当结肠腺癌发展到 III 期阶段，逐渐侵犯到结肠壁和周围组织，并向淋巴结转移，ECM 发生过渡降解促进肿瘤表达，同时免疫细胞分泌细胞因子，诱导成纤维细胞活化并分泌 ECM 成分，从而形成促癌微环境^[33]。

TCGA-COAD 的 DNB 模块的 KEGG 通路富集分析（B 和 D）主要围绕免疫失调以及炎症信号传导。随着结直肠癌的演进，体内免疫系统负担逐渐加重，由免疫系统引发的炎症反应越来越剧烈。相关研究证明结肠腺癌与由结肠炎相关，由于长期暴露于慢性炎症而转变为结肠腺癌^[34]。




图 3.3-3 TCGA-COAD 的 GO 与 KEGG 通路富集分析组图

如图 3.3-4 所示，TCGA-READ 的 DNB 模块的 GO 通路富集分析（A 和 C）同样围绕细胞外基质动态调控以及免疫-微环境互作两大核心生物功能。当直肠腺癌发展到 IV 期阶段，开始向全省扩散，并形成肝转移和肺转移，ECM 会促进肿瘤表达并形成促癌环境。同样的，KEGG 通路富集分析（B 和 D）显示出了与结肠腺癌类似的免疫失调以及炎症信号。

由此可见，结肠腺癌和直肠腺癌均作为结直肠癌的组成部分，具有高度的相似性。在临床上，可以互相作为先验案例对实际情况进行指导。




图 3.3-4 TCGA-READ 的 GO 与 KEGG 通路富集分析组图

第四章 论文总结

4.1 总结

本研究在过去研究的基础上，提出了由简单统计指标驱动的个体特异性因果网络熵方法。通过基因调控网络数值模拟，证明了提出方法的稳定性与有效性，为在真实世界中应用方法提供理论指导。在来自 GEO 数据库的 H3N2 流感数据集 GSE30550 上，使用本研究方法计算了 17 个具有不同特征的受试对象的个体特异性因果熵值，结果显示本研究方法可以提前临床症状出现事件检测到疾病恶化信号，同时，DNB 模块通路富集分析结果显示 H3N2 流感病毒利用宿主因子促进复制并拮抗宿主产生的干扰素，引发宿主机体的免疫应激反应。本研究方法在 H3N2 流感数据上的成功应用，为下一步在未知情况下预测疾病临界点夯实了基础。在来自 TCGA 数据库的结肠腺癌 TCGA-COAD 和直肠腺癌 TCGA-READ 数据上，使用本研究方法，计算了不同临床分期阶段的特异性因果网络熵值，结果显示临床 III 期为结肠腺癌的关键转变点，临床 IV 期是直肠腺癌的关键转变点，通过 KM 生存分析验证了临床 III 期和临床 IV 期作为关键转变点的有效性。同时，DNB 模块通路富集分析显示结肠腺癌和直肠腺癌作为结直肠癌的组成部分，具有高度相似性，均与细胞外基质以及炎症反应有关。本研究从个体层面出发，解决了先前研究停留在静态非动态的问题，同时将基因以网络的方式联系起来，更加全面的观察疾病演进过程

4.2 展望

本研究方法从个体水平定量分析复杂疾病的进展过程并预测恶化前关键状态的时刻，简化了因果网络的构建方式，平衡了基因间因果强度与基因波动度的影响，准确识别了 DNB 模块关键基因。当然，本研究还存在缺点：（1）在构建因果网络容易受到单个基因出现极端情况的影响；（2）在进行生存差异分析时，样本量不足导致生存差异并不显著，具有一定的局限性和片面性。

本研究方法需要继续改进，扩大研究范围，以适应更多复杂疾病以及更极端的样本情况，在临床关键转变点监测，细胞命运捕捉以及免疫检查点研究方面继续深入。

参考文献

- [1] Li X, Zhu Q, Zhao C, et al. Tipping Point Detection Using Reservoir Computing[J]. Research, 2023, 6: 0174.
- [2] Clough E, Barrett T, Wilhite S E, et al. NCBI GEO: archive for gene expression and epigenomics data sets: 23-year update[J]. Nucleic Acids Research, 2024, 52(D1): D138-D144.
- [3] Huang Y, Zaas A K, Rao A, et al. Temporal Dynamics of Host Molecular Responses Differentiate Symptomatic and Asymptomatic Influenza A Infection[J]. PLoS Genetics, 2011, 7(8): e1002234.
- [4] The Cancer Genome Atlas Research Network, Weinstein J N, Collisson E A, et al. The Cancer Genome Atlas Pan-Cancer analysis project[J]. Nature Genetics, 2013, 45(10): 1113-1120.
- [5] The Cancer Genome Atlas Network. Comprehensive molecular characterization of human colon and rectal cancer[J]. Nature, 2012, 487(7407): 330-337.
- [6] Chen L, Liu R, Liu Z P, et al. Detecting early-warning signals for sudden deterioration of complex diseases by dynamical network biomarkers[J]. Scientific Reports, 2012, 2(1): 342.
- [7] Szklarczyk D, Kirsch R, Koutrouli M, et al. The STRING database in 2023: protein–protein association networks and functional enrichment analyses for any sequenced genome of interest[J]. Nucleic Acids Research, 2023, 51(D1): D638-D646.
- [8] Liu R, Yu X, Liu X, et al. Identifying critical transitions of complex diseases based on a single sample[J]. Bioinformatics, 2014, 30(11): 1579-1586.
- [9] Chen P, Liu R, Li Y, et al. Detecting critical state before phase transition of complex biological systems by hidden Markov model[J]. Bioinformatics, 2016, 32(14): 2143-2150.
- [10] Chen P, Li Y, Liu X, et al. Detecting the tipping points in a three-state model of complex diseases by temporal differential networks[J]. Journal of Translational Medicine, 2017, 15(1): 217.
- [11] Liu X, Chang X, Leng S, et al. Detection for disease tipping points by landscape dynamic network biomarkers[J]. National Science Review, 2019, 6(4): 775-785.
- [12] Han C, Zhong J, Hu J, et al. Single-Sample Node Entropy for Molecular Transition in Pre-deterioration Stage of Cancer[J]. Frontiers in Bioengineering and Biotechnology, 2020, 8: 809.
- [13] Zhong J, Han C, Wang Y, et al. Identifying the critical state of complex biological systems by the directed-network rank score method[J]. Bioinformatics, 2022, 38(24): 5398-5405.
- [14] Zhong J, Tang H, Huang Z, et al. Uncovering the Pre-Deterioration State during Disease Progression Based on Sample-Specific Causality Network Entropy (SCNE)[J]. Research, 2024, 7: 0368.
- [15] Yan J, Li P, Li Y, et al. Disease prediction by network information gain on a single sample basis[J]. Fundamental Research, 2025, 5(1): 215-227.
- [16] Chen P, Liu R, Chen L, et al. Identifying critical differentiation state of MCF-7 cells for breast cancer by dynamical network biomarkers[J]. Frontiers in Genetics, 2015, 6.
- [17] Liu R, Wang J, Ukai M, et al. Hunt for the tipping point during endocrine resistance process in breast cancer by dynamic network biomarkers[J]. Journal of Molecular Cell Biology, 2019, 11(8): 649-664.
- [18] Sun Y, Zhao H, Wu M, et al. Identifying critical states of hepatocellular carcinoma based on landscape dynamic network biomarkers[J]. Computational Biology and Chemistry, 2020, 85: 107202.
- [19] Johnson K A, Goody R S. The Original Michaelis Constant: Translation of the 1913 Michaelis–

- Menten Paper[J]. *Biochemistry*, 2011, 50(39): 8264-8269.
- [20] Foo M, Kim J, Bates D G. Modelling and Control of Gene Regulatory Networks for Perturbation Mitigation[J]. *IEEE/ACM Transactions on Computational Biology and Bioinformatics*, 2019, 16(2): 583-595.
- [21] Edalat A, Farjudian A, Li Y. Recursive solution of initial value problems with temporal discretization[J]. *Theoretical Computer Science*, 2023, 980: 114221.
- [22] Zhang M, Zhou L, Fu D, et al. An Integrated Taylor Expansion and Least Squares Approach to Enhanced Acoustic Wave Staggered Grid Finite Difference Modeling[J]. *Applied Sciences*, 2024, 14(21): 10076.
- [23] The Gene Ontology Consortium, Aleksander S A, Balhoff J, et al. The Gene Ontology knowledgebase in 2023[J]. *GENETICS*, 2023, 224(1): iyad031.
- [24] Kanehisa M. KEGG: Kyoto Encyclopedia of Genes and Genomes[J]. *Nucleic Acids Research*, 2000, 28(1): 27-30.
- [25] Emile S H, Horesh N, Freund M R, et al. Trends in the Characteristics, Treatment, and Outcomes of Rectal Adenocarcinoma in the US From 2004 to 2019: A National Cancer Database Analysis[J]. *JAMA Oncology*, 2023, 9(3): 355.
- [26] Atkin W, Wooldrage K, Brenner A, et al. Adenoma surveillance and colorectal cancer incidence: a retrospective, multicentre, cohort study[J]. *The Lancet Oncology*, 2017, 18(6): 823-834.
- [27] De Torrenté L, Zimmerman S, Suzuki M, et al. The shape of gene expression distributions matter: how incorporating distribution shape improves the interpretation of cancer transcriptomic data[J]. *BMC Bioinformatics*, 2020, 21(S21): 562.
- [28] Allen J D, Ross T M. H3N2 influenza viruses in humans: Viral mechanisms, evolution, and evaluation[J]. *Human Vaccines & Immunotherapeutics*, 2018, 14(8): 1840-1847.
- [29] Wang J, Zhang Y, Sun L, et al. Eukaryotic RNA binding protein hnRNPH1 suppresses influenza A virus replication through interaction with virus NS1 protein[J]. *Emerging Microbes & Infections*, 2025, 14(1): 2477645.
- [30] Amin M B, Greene F L, Edge S B, et al. The Eighth Edition AJCC Cancer Staging Manual: Continuing to build a bridge from a population-based to a more “personalized” approach to cancer staging[J]. *CA: A Cancer Journal for Clinicians*, 2017, 67(2): 93-99.
- [31] Han C, Zhong J, Zhang Q, et al. Development of a dynamic network biomarkers method and its application for detecting the tipping point of prior disease development[J]. *Computational and Structural Biotechnology Journal*, 2022, 20: 1189-1197.
- [32] Stalpers L J A, Kaplan E L. Edward L. Kaplan and the Kaplan-Meier Survival Curve[J]. *BSHM Bulletin: Journal of the British Society for the History of Mathematics*, 2018, 33(2): 109-135.
- [33] Nersisyan S, Novosad V, Engibaryan N, 等. ECM–Receptor Regulatory Network and Its Prognostic Role in Colorectal Cancer[J]. *Frontiers in Genetics*, 2021, 12: 782699.
- [34] Levi-Galibov O, Lavon H, Wassermann-Dozorets R, et al. Heat Shock Factor 1-dependent extracellular matrix remodeling mediates the transition from chronic intestinal inflammation to colon cancer[J]. *Nature Communications*, 2020, 11(1): 6245.

致 谢

行文至此落笔中，始于初秋终于夏。再一次感叹时光匆匆如白驹过隙，脑海中仍回荡着四年的点点滴滴。这一路，走得坎坷也走得踏实。感谢永远挺胸抬头的自己。

这一路，感谢师长！感谢言方荣老师，一直记得言老师的一句话“生物统计是一门科学，也是一门艺术”，让我笃定要投身于临床试验研究这一领域；感谢本论文指导老师房婧雅老师，接触这个课题实则有一年半的时间，也一直都是房老师在指导，在这个课题中学到了非常多的技能，如何去读文献，如何去完整设计方法，如何去讲好一个论文故事。当然，也要感谢生物统计系的其他老师，感谢蒋丽芸老师，感谢刘甜甜老师，感谢刘颖博老师，感谢高祖新老师，感谢王菲老师，感谢阎航宇老师，感谢时常关心我的江波老师！不分先后顺序。当然，还要感谢理学院学工团队，赵飞老师，张旭老师，朱赫老师，郭敏丽老师，努尔老师，让我在成长过程中收获颇多。

这一路，感谢父母！此处无需多言，父上母上是我的老天爷。

这一路，感谢身边存在的美好！感谢陈颖同学这一阶段的关心，支持与鼓励，让我有动力去攀登高峰！感谢身边的老铁们，时常回来聚一聚！

这一趟旅程就走到这里，我们下一趟旅程再会！